



Universidade Estadual de Campinas
Instituto de Matemática, Estatística e Computação Científica

ME607 — Séries Temporais

Aluísio de Souza Pinheiro

Modelo Bayesiano de Coeficientes Variáveis no Tempo

Bayesian Time-Varying Coefficient (BTVC) / KTR

Thales de Souza Crivillari
RA: 236312

Projeto P1
17 de abril de 2026

Sumário

1	Introdução e Motivação	2
2	Formulação do Modelo BTVC	2
2.1	Modelo Multiplicativo de Mix de Marketing	2
2.2	Representação Log-Log e Coeficientes Variáveis	3
2.3	Variáveis Latentes e Kernel Weighting	4
2.4	Tendência e Sazonalidade como Coeficientes Variáveis	5
2.5	Seleção de Kernels	6
2.6	Estrutura Hierárquica Bayesiana	7
2.7	Inferência: Stochastic Variational Inference (SVI)	8
3	Implementação: Pacote Orbit e Classe KTR	9
4	Ilustração Empírica: Dataset iclaims	9
4.1	Descrição do Conjunto de Dados	9
4.2	Análise Exploratória	10
4.3	Análise das Diferenças e Funções de Autocorrelação	11
4.4	Configuração, Ajuste e Decomposição do Modelo	13
4.5	Métricas de Desempenho	15
5	Discussão Crítica	16
6	Conclusão	17

1 Introdução e Motivação

A maioria dos modelos clássicos de séries temporais, como os modelos $\text{ARIMA}(p, d, q)$, $\text{SARIMA}(p, d, q)(P, D, Q)_S$, suavização exponencial e ARMAX , assume que os **parâmetros de regressão são constantes ao longo do tempo**. Essa hipótese, embora matematicamente conveniente, pode ser inadequada em contextos econômicos e de marketing, nos quais as relações entre variáveis evoluem continuamente em resposta a mudanças estruturais, comportamentais ou exógenas.

O **Modelo Bayesiano de Coeficientes Variáveis no Tempo** (*Bayesian Time-Varying Coefficient* BTVC), proposto por Ng, Wang e Dai (2021), representa uma solução elegante para esse problema. Motivado pela necessidade de aprimorar o *Marketing Mix Modeling* (MMM) na empresa Uber Technologies, o BTVC combina três elementos metodológicos centrais: (i) **suavização por kernel** para construir coeficientes dinâmicos; (ii) um **framework Bayesiano hierárquico** que permite incorporar experimentos controlados como priors; e (iii) **Inferência Variacional Estocástica** (SVI) para estimação eficiente em alta dimensão.

Este trabalho apresenta uma exposição detalhada do modelo BTVC, ilustrando-o com o *dataset iclaims* série semanal de pedidos iniciais de seguro-desemprego nos EUA (2010–2018) com regressores do Google Trends.

2 Formulação do Modelo BTVC

2.1 Modelo Multiplicativo de Mix de Marketing

Expressar a resposta como função multiplicativa de variáveis de gasto, com retornos marginais decrescentes, é propriedade fundamental de modelos de atribuição de marketing (Farris *et al.*, 2015). O modelo tem a forma geral:

$$\hat{y}_t = g(t) \cdot \prod_{p=1}^P f_{t,p}(x_{t,p}), \quad t = 1, \dots, T \quad (1)$$

onde cada símbolo tem o seguinte significado:

Símbolo	Descrição
$\hat{y}_t$	Resposta prevista pelo modelo no instante t (ex.: volume de vendas)
$g(t)$	Componente de série temporal: tendência + sazonalidade conjuntas
$\prod_{p=1}^P$	Produto sobre os P canais de marketing (regressores)
$f_{t,p}(\cdot)$	Função de custo do canal p : crescente, diferenciável e côncava (captura retornos marginais decrescentes do gasto em mídia)
$x_{t,p}$	Gasto no canal p no instante t
P	Número total de canais (regressores exógenos)
T	Número de observações temporais

2.2 Representação Log-Log e Coeficientes Variáveis

Aplicando a transformação $\ln(\cdot)$ à Equação (1) com a escolha $f_{t,p}(x_{t,p}) = x_{t,p}^{\beta_{t,p}}$ (função potência, que garante retornos decrescentes para $0 \leq \beta_{t,p} \leq 1$), obtém-se a representação **log-log aditiva**:

$$\ln(\hat{y}_t) = \underbrace{l_t}_{\text{tendência dinâmica}} + \underbrace{s_t}_{\text{sazonalidade adaptativa}} + \underbrace{\sum_{p=1}^P \ln(x_{t,p}) \beta_{t,p}}_{r_t = \text{componente de regressão}} \quad (2)$$

Interpretação de cada componente:

- **Tendência** l_t : componente de longo prazo, análoga ao parâmetro de nível μ_t em um modelo de espaço de estados. Ao contrário de um modelo ARIMA(p, d, q) onde a tendência é capturada pela diferenciação de ordem d (ex.: $d = 1$ para tendência linear), aqui l_t é uma função suave e variante no tempo, estimada por kernel. Não há hipótese de linearidade.
- **Sazonalidade** s_t : padrão periódico de período S , modelado por funções de Fourier com coeficientes que variam no tempo. Em um SARIMA(p, d, q)(P, D, Q) $_S$, a sazonalidade é capturada por diferenciação sazonal de ordem D e pelos operadores P e Q sazonais, assumindo padrão fixo. Aqui, s_t é *adaptativa*.
- **Coeficientes** $\beta_{t,p}$: elasticidade do canal p no instante t . Em modelos ARMAX ou regressão linear clássica, $\beta_{t,p} \equiv \beta_p$ seria um escalar fixo. No BTVC, $\beta_{t,p}$ é

uma **função do tempo**, capturando como o efeito de cada regressor evolui. O intervalo $[0, 1]$ garante retornos decrescentes (elasticidade menor que 1).

- $\ln(x_{t,p})$: ao tomar o log do gasto, a relação potência x^β torna-se linear em β , facilitando a estimação. Este é o truque da regressão log-log clássica.

2.3 Variáveis Latentes e Kernel Weighting

A ideia central do BTVC é expressar cada coeficiente $\beta_{t,p}$ como **combinação ponderada de J variáveis latentes** $b_{j,p}$, distribuídas em pontos âncora (*knots*) $t_1, \dots, t_J$ ao longo do eixo temporal:

$$\underbrace{\beta_{t,p}}_{\substack{\text{coeficiente do} \\ \text{regressor } p \\ \text{no instante } t}} = \sum_{j=1}^J \underbrace{w_j(t)}_{\substack{\text{peso kernel} \\ \text{normalizado} \\ \text{(Eq. 4)}}} \cdot \underbrace{b_{j,p}}_{\substack{\text{variável latente} \\ \text{no nó } t_j \\ \text{(análogo a um knot} \\ \text{de spline)}}} \quad (3)$$

Os pesos de kernel são normalizados para que $\sum_j w_j(t) = 1$ para todo t , conferindo a $\beta_{t,p}$ uma interpretação de **média ponderada local** das variáveis latentes:

$$w_j(t) = \frac{\overbrace{k(t, t_j)}^{\substack{\text{função kernel:} \\ \text{mede proximidade} \\ \text{entre } t \text{ e } t_j}}}{\underbrace{\sum_{i=1}^J k(t, t_i)}_{\text{normalização}}} \quad (4)$$

Em **notação matricial**, o conjunto completo de coeficientes é dado por:

$$\underbrace{\beta}_{\substack{T \times P \\ \text{coeficientes} \\ \text{para todos os} \\ \text{instantes e canais}}} = \underbrace{K}_{\substack{T \times J \\ \text{matriz de pesos} \\ \text{de kernel} \\ w_j(t) \text{ normaliz.}}} \cdot \underbrace{b}_{\substack{J \times P \\ \text{matriz de} \\ \text{variáveis latentes} \\ \text{(knots)}}} \quad (5)$$

Analogia com modelos conhecidos:

- Em um modelo **AR(1)**, o coeficiente ϕ_1 é um escalar fixo. Aqui, $\beta_{t,p}$ é um vetor de T valores, cada um uma combinação dos J knots, análogo a um spline de dimensão J .
- Em regressão por **splines**, os knots definem uma base e os coeficientes são estimados por mínimos quadrados penalizados. No BTVC, os knots $b_{j,p}$ são variáveis

aleatórias com prioris Bayesianas, e a suavização é induzida pelo kernel em vez de uma penalidade explícita.

A componente de regressão da série é então:

$$r_t = \underbrace{\mathbf{X}_t}_{\substack{1 \times P \\ \text{vetor de log-gastos} \\ \text{no instante } t}} \cdot \underbrace{\boldsymbol{\beta}_t^\top}_{\substack{P \times 1 \\ \text{vetor de coeficientes} \\ \beta_{t,1}, \dots, \beta_{t,P}}} = \sum_{p=1}^P \ln(x_{t,p}) \beta_{t,p} \quad (6)$$

2.4 Tendência e Sazonalidade como Coeficientes Variáveis

A mesma estrutura de kernel é aplicada à tendência e à sazonalidade. **Tendência** (intercept dinâmico):

$$\begin{aligned} \boldsymbol{\beta}_{\text{lev}} &= \underbrace{\mathbf{K}_{\text{lev}}}_{\substack{T \times J \\ \text{kernel triangular} \\ \text{(Eq. 10)}}} \cdot \underbrace{\mathbf{b}_{\text{lev}}}_{\substack{J \times 1 \\ \text{knots de} \\ \text{tendência}}} \\ l_t &= \beta_{t,\text{lev}} \quad \left(\text{tendência no instante } t \right) \end{aligned} \quad (7)$$

Sazonalidade (via Fourier com coeficientes dinâmicos):

$$\begin{aligned} \boldsymbol{\beta}_{\text{seas}} &= \underbrace{\mathbf{K}_{\text{seas}}}_{\substack{T \times J \\ \text{kernel triangular} \\ \text{sazonal}}} \cdot \underbrace{\mathbf{b}_{\text{seas}}}_{\substack{J \times 1 \\ \text{knots} \\ \text{sazonais}}} \\ s_t &= \underbrace{\mathbf{X}_{t,\text{seas}}}_{\substack{1 \times 2K_{\text{ord}} \\ \text{funções de Fourier} \\ \cos(2k\pi t/S), \sin(2k\pi t/S) \\ \text{para } k=1, \dots, K_{\text{ord}}}} \cdot \underbrace{\boldsymbol{\beta}_{t,\text{seas}}^\top}_{\substack{2K_{\text{ord}} \times 1 \\ \text{coeficientes sazonais} \\ \text{variáveis no tempo}}} \end{aligned} \quad (8)$$

Interpretação: Em um SARIMA(0, 0, 0)(1, 1, 0)₅₂ (puramente sazonal, por exemplo), a sazonalidade seria capturada por um operador de diferença sazonal ∇_{52} e por um coeficiente AR sazonal Φ_1 fixo. Aqui, os coeficientes de Fourier são funções suaves de t , permitindo que a amplitude e a fase da sazonalidade variem ao longo dos anos, comportamento que um SARIMA com coeficientes fixos não captura.

As funções de Fourier de período S e ordem k são:

$$\underbrace{\cos\left(\frac{2k\pi t}{S}\right)}_{\text{componente cossenoidal}} \quad \text{e} \quad \underbrace{\sin\left(\frac{2k\pi t}{S}\right)}_{\text{componente senoidal}}, \quad k = 1, \dots, K_{\text{ord}} \quad (9)$$

Por exemplo, para dados **semanais**: $S = 52$ captura a **sazonalidade anual** (um ciclo completo a cada 52 semanas); $S = 7$ capturaria a **sazonalidade semanal** (dias da semana), se os dados fossem diários.

2.5 Seleção de Kernels

Para tendência e sazonalidade, o paper propõe um **kernel triangular customizado** (interpolação linear entre nós adjacentes):

$$k_{\text{lev}}(t, t_j) = \underbrace{1 - \frac{|t - t_j|}{t_{i+1} - t_i}}_{\substack{\text{peso inversamente} \\ \text{proporcional à distância} \\ \text{temporal entre } t \text{ e } t_j}} \quad \text{quando} \quad \underbrace{t_i \leq t \leq t_{i+1}}_{\substack{\text{apenas knots} \\ \text{adjacentes têm} \\ \text{peso não-nulo}}} \quad (10)$$

Fora do intervalo $[t_i, t_{i+1}]$, o peso é zero. Isso garante que a tendência seja uma função **linear por partes** entre os knots, semelhante a uma spline linear, mas com coeficientes aleatórios.

Para os coeficientes de regressão, adota-se o **kernel Gaussiano** (suavização mais suave, com influência gradual decaindo com a distância):

$$k_{\text{reg}}(t, t_j; \rho) = \exp \left(- \frac{\overbrace{(t - t_j)^2}^{\text{distância quadrática}}}{\underbrace{2\rho^2}_{\substack{\text{controla a} \\ \text{largura da} \\ \text{suavização:} \\ \rho \text{ grande} = \text{mais suave;} \\ \rho \text{ pequeno} = \text{mais local}}}} \right) \quad (11)$$

Comparação com kernels da literatura: O kernel Gaussiano da Equação (11) é o mesmo usado em Processos Gaussianos e em estimadores de Nadaraya-Watson. Kernels alternativos como o Epanechnikov $k(u) = \frac{3}{4}(1 - u^2)\mathbf{1}_{|u| \leq 1}$ ou o quadrático também são suportados pelo Orbit.

2.6 Estrutura Hierárquica Bayesiana

Ao invés de estimar os knots $\mathbf{b}$ diretamente por otimização, o BTVC trata-os como **variáveis aleatórias** com priors especificadas.

Para tendência e sazonalidade, priori de Laplace com dependência sequencial (análogo ao modelo de pontos de mudança do Prophet):

$$b_{j,\text{lev}} \sim \mathcal{L} \left(\underbrace{\begin{array}{c} \text{nó anterior:} \\ \text{priori centrada} \\ \text{no nó precedente} \\ b_{j-1,\text{lev}} \end{array}}_{\text{distribuição de Laplace:}} , \underbrace{\begin{array}{c} \text{escala:} \\ \text{controla a} \\ \text{volatilidade} \\ \text{da tendência} \\ \sigma_{\text{lev}} \end{array}}_{\text{caudas mais pesadas que a Normal,}} \right) \quad (12)$$

promove mudanças esparsas
(análogo à penalidade LASSO)

$$b_{j,\text{seas}} \sim \mathcal{L}(b_{j-1,\text{seas}}, \sigma_{\text{seas}}) \quad (13)$$

Interpretação: A priori de Laplace centrada no nó anterior induz suavidade sequencial na tendência, mudanças grandes são penalizadas, mas permitidas (cauda pesada).

Para regressão, hierarquia de dois níveis com Normal truncada positiva (garante que elasticidades de gasto sejam não-negativas):

$$\mu_{\text{pool}} \sim \underbrace{\mathcal{N}^+(0, \sigma_{\text{pool}}^2)}_{\substack{\text{priori para a} \\ \text{média global do pool} \\ \text{de todos os canais}}} \quad (14)$$

$$\mu_{\text{reg}} \sim \mathcal{N}^+ \left(\underbrace{\begin{array}{c} \text{média global:} \\ \text{efeito de pooling} \\ \text{entre canais} \\ \mu_{\text{pool}} \end{array}}_{\text{nível 1 da hierarquia:}} , \sigma_{\text{pool}}^2 \right) \quad (15)$$

média de longo prazo
do coeficiente de cada canal

$$b_{\text{reg}} \sim \mathcal{N}^+ \left(\underbrace{\begin{array}{c} \text{puxa os knots} \\ \text{em direção à} \\ \text{média do canal} \\ \mu_{\text{reg}} \end{array}}_{\text{nível 2: variáveis latentes}} , \sigma_{\text{reg}}^2 \right) \quad (16)$$

locais (knots) do canal;
encolhem para μ_{reg} quando
o canal não tem gasto

Interpretação da hierarquia:

- μ_{reg} representa a elasticidade média de longo prazo do canal, o equivalente ao β_p fixo de uma regressão clássica ou de um modelo AR(1) com regressor.
- Nos períodos sem gasto ($x_{t,p} \approx 0$), os knots $b_{j,p}$ “encolhem” (*shrinkage*) em direção a μ_{reg} , em vez de para zero, evitando estimativas espúrias.
- $\mathcal{N}^+$ denota a **distribuição Normal truncada em zero** (apenas valores positivos), garantindo que $\beta_{t,p} \geq 0$ (elasticidade de gasto deve ser não-negativa).
- Essa estrutura é chamada de **efeito de pooling** em modelos hierárquicos Bayesianos (Gelman *et al.*, 2013).

2.7 Inferência: Stochastic Variational Inference (SVI)

A distribuição posterior conjunta de todas as variáveis latentes $\mathbf{b} = (\mathbf{b}_{\text{reg}}, \mathbf{b}_{\text{lev}}, \mathbf{b}_{\text{seas}})$ é intratável analiticamente. Em vez de MCMC (custoso para alta dimensão), o BTVC utiliza **Inferência Variacional Estocástica** (Hoffman *et al.*, 2013), que aproxima a posterior por uma família paramétrica $q_\phi(\mathbf{b})$, minimizando a divergência KL:

$$\phi^* = \arg \min_{\phi} D_{\text{KL}} \left[\underbrace{\begin{array}{c} \text{aproximação variacional:} \\ \text{família Normal} \\ \text{mean-field (fatorada)} \\ q_\phi(\mathbf{b}) \end{array} \parallel \begin{array}{c} \text{posterior verdadeira:} \\ \text{intratável analiticamente} \\ p(\mathbf{b} \mid \mathbf{y}) \end{array}}_{\substack{\text{divergência de Kullback-Leibler:} \\ \text{mede discrepância entre} \\ q_\phi \text{ e a posterior real}}} \right] \equiv \underbrace{-\text{ELBO}(\phi)}_{\substack{\text{maximizar ELBO} \\ \equiv \text{minimizar } D_{\text{KL}}}} \quad (17)$$

O ELBO (*Evidence Lower Bound*) é:

$$\text{ELBO}(\phi) = \underbrace{\mathbb{E}_{q_\phi}[\ln p(\mathbf{y} \mid \mathbf{b})]}_{\substack{\text{verossimilhança esperada:} \\ \text{ajuste aos dados}}} - \underbrace{D_{\text{KL}}[q_\phi(\mathbf{b}) \parallel p(\mathbf{b})]}_{\substack{\text{regularização:} \\ \text{quanto } q_\phi \text{ desvia} \\ \text{das priors}}} \quad (18)$$

A SVI otimiza o ELBO via gradiente estocástico(Adam), usando mini-batches de dados a cada iteração escalonando bem para séries longas e modelos com muitos regressores ($P \sim 50$).

3 Implementação: Pacote Orbit e Classe KTR

O BTVC está implementado no pacote open-source **Orbit** (*Orbital Bayesian Time-Series*) (Ng; Wang; Chen *et al.*, 2021), desenvolvido pela Uber. A versão 1.1 introduziu a classe **KTR** (*Kernel Time-varying Regression*), que encapsula todo o framework BTVC com interface familiar (inicializar → ajustar → prever).

Instalação e uso básico:

```
pip install orbit-ml
```

```
from orbit.models import KTR
```

```
from orbit.utils.dataset import load_iclaims
```

```
df = load_iclaims()    # Dataset iclaims (443 semanas, 2010–2018)
```

```
ktr = KTR(
```

```
    response_col    = "claims",                # variável resposta: log(claims)
```

```
    date_col        = "week",                  # coluna de datas semanais
```

```
    regressor_col   = ["trend.unemploy",        # regressores: Google Trends
```

```
                        "trend.filling",
```

```
                        "trend.job"],
```

```
    regressor_sign  = ["=", "=", "="],          # sinais livres (não necessariamente +)
```

```
    seasonality     = [52],                    # sazonalidade anual (S=52 semanas)
```

```
    estimator       = "pyro-svi",              # SVI via Pyro (alternativa: "stan-map")
```

```
    n_bootstrap_draws = 500,                    # amostras da posterior aproximada
```

```
    num_steps       = 500,                      # iterações da SVI
```

```
    seed           = 2024,
```

```
)
```

```
ktr.fit(df=df_train)
```

```
pred = ktr.predict(df=df_test, decompose=True)
```

4 Ilustração Empírica: Dataset iclaims

4.1 Descrição do Conjunto de Dados

O *dataset* `iclaims`, disponível via `orbit.utils.dataset.load_iclaims()`, contém $T = 443$ observações semanais (de 3 de janeiro de 2010 a 24 de junho de 2018) da série de pedidos iniciais de seguro-desemprego nos EUA, em escala logarítmica. Os dados de pedidos foram obtidos do Federal Reserve Bank of St. Louis (série ICNSA), enquanto

os regressores provêm da API do Google Trends (Ng; Wang; Chen *et al.*, 2021). A Tabela 1 descreve as variáveis do conjunto.

Tabela 1: Variáveis do dataset `iclaims`.

Variável	Tipo	Descrição
<code>claims</code>	Resposta	$\ln(\text{pedidos iniciais de seguro-desemprego})$
<code>trend.unemploy</code>	Regressor	Índice de buscas por “unemployment”
<code>trend.filling</code>	Regressor	Índice de buscas por “unemployment filling”
<code>trend.job</code>	Regressor	Índice de buscas por “job”

4.2 Análise Exploratória

A Figura 1 apresenta a série resposta e os três regressores ao longo de todo o período.




Figura 1: **Análise exploratória do dataset `iclaims` (2010–2018)**. Painel superior: série $Y_t = \ln(\text{claims})$, com tendência decrescente e sazonalidade anual. Painéis intermediários e inferior: regressores de Google Trends (`trend.unemploy`, `trend.filling`, `trend.job`).

A série Y_t apresenta tendência decrescente contínua ao longo de 2010–2018, reflexo da recuperação gradual do mercado de trabalho norte-americano após a crise de 2008, com valores que partem de aproximadamente 13,5 e chegam a 12,2 no final do período. Sobreposta à tendência, observa-se sazonalidade anual bem definida: os pedidos de desemprego sobem no início do ano (janeiro e fevereiro) e recuam no segundo semestre.

Os regressores de Google Trends revelam comportamentos distintos. O índice `trend.unemploy` (laranja) apresenta uma **quebra estrutural pronunciada em meados de 2014–2015**: o sinal cai abruptamente para valores próximos de -1 e então sobe de volta, o que coincide com uma reindexação da base de referência do Google Trends naquele período. Esse tipo de descontinuidade seria problemático em modelos com coeficientes fixos, pois apareceria como um nível artificialmente negativo para o regressor. O BTVC acomoda naturalmente essa mudança por meio do kernel weighting, ajustando $\hat{\beta}_{t,\text{unemploy}}$ antes e depois da quebra. O índice `trend.filling` (verde) exibe picos sazonais anuais marcados, enquanto `trend.job` (vermelho) oscila em torno de zero com amplitude reduzida.

4.3 Análise das Diferenças e Funções de Autocorrelação

Para avaliar a estacionaridade da série e identificar sua estrutura de dependência temporal, examinamos Y_t e suas duas primeiras diferenças, além das Funções de Autocorrelação (FAC) e Autocorrelação Parcial (FACP).




Figura 2: Série Y_t e suas diferenças (dataset iclaims). A linha tracejada cinza indica o zero nas séries diferenciadas.

A Figura 2 mostra que Y_t é claramente não-estacionária: tendência e sazonalidade dominam. A primeira diferença ΔY_t elimina a tendência e centraliza a série em torno de zero, mas vestígios sazonais permanecem visíveis. A segunda diferença $\Delta^2 Y_t$, apresentada apenas para fins comparativos, produz variância maior que ΔY_t , antecipando o diagnóstico de sobre-diferenciação que a FAC confirmará.

Tabela 2: Estatísticas descritivas de Y_t , ΔY_t e $\Delta^2 Y_t$ (dados reais do iclaims).

Série	Obs.	Média	Variância	Mín.	Máx.
Y_t	443	12,660	0,0779	12,136	13,624
ΔY_t	442	-0,002	0,0134	-0,342	0,381
$\Delta^2 Y_t$	441	-0,000	0,0334	-0,631	0,573

A variância de ΔY_t é cerca de seis vezes menor que a de Y_t , confirmando que tendência e sazonalidade respondem pela maior parte da variabilidade original.




Figura 3: **Painel resumo: série, FAC e FACP de Y_t , ΔY_t e $\Delta^2 Y_t$ (iclaims).** Banda vermelha: IC de 95% ($\pm 1,96/\sqrt{n}$). Linha laranja pontilhada: lag 52 (1 ano).

A Figura 3 apresenta os resultados para as três séries. A FAC de Y_t decai muito lentamente, permanecendo significativa por dezenas de lags, padrão característico de série não-estacionária. A FACP de Y_t exibe pico dominante no lag 1 ($\hat{\phi}_{11} \approx 1$), confirmando forte persistência. Após a primeira diferença, a FAC de ΔY_t cai rapidamente, com apenas os lags 1 e 2 e um resíduo sazonal no lag 52 significativos, enquanto a FACP

aponta componentes de curta memória nos mesmos lags. Já a FAC de $\Delta^2 Y_t$ apresenta valor negativo e significativo no lag 1, padrão de sobre-diferenciação, confirmando que $d = 1$ é suficiente.

Em suma, a análise exploratória evidencia que Y_t é não-estacionária, possui dependência de curta memória após diferenciação e exibe sazonalidade anual e regressores com dinâmicas que variam ao longo do tempo — características que motivam diretamente o uso do modelo BTVC.

4.4 Configuração, Ajuste e Decomposição do Modelo

Com base na análise exploratória, o modelo KTR é configurado com os três regressores de Google Trends, sazonalidade anual ($S = 52$, Equação 9), $J = 10$ knots uniformemente distribuídos, kernel Gaussiano para a componente de regressão (Equação 11) e estimação via SVI com 500 iterações. O conjunto de dados é dividido em treino (primeiras 391 semanas, jan/2010–jun/2017) e teste (últimas 52 semanas, jul/2017–jun/2018).



Figura 4: **Ajuste e previsão do modelo KTR (BTVC) no conjunto iclaims.** A linha contínua preta mostra os dados de treino; a linha tracejada, os dados de teste; a linha vermelha, a previsão pontual; a banda rosa, o intervalo de credibilidade de 90%. A linha pontilhada vertical marca o início do período de teste.

A Figura 4 mostra que o modelo captura bem a dinâmica da série. No período de teste (última porção do gráfico), a previsão acompanha o padrão sazonal observado, o vale de verão e a recuperação do início de 2018, dentro do intervalo de credibilidade de 90%. O alargamento progressivo da banda reflete o crescimento natural da incerteza com o horizonte de previsão.




Figura 5: **Decomposição do sinal pelo modelo KTR:** série observada (preto), tendência l_t (azul), sazonalidade s_t (verde) e componente de regressão r_t (laranja). Período de treino (jan/2010–jun/2017).

A Figura 5 apresenta a decomposição $\hat{Y}_t = l_t + s_t + r_t$ estimada pelo modelo. Três aspectos merecem destaque:

Tendência l_t (painel azul). Declínio suave e contínuo de 13,1 em janeiro de 2010 para 12,3 em meados de 2017, capturando a recuperação gradual do mercado de trabalho norte-americano. A curva é monotonicamente decrescente e sem oscilações abruptas, resultado direto do kernel triangular (Equação 10) que impõe suavidade entre os knots consecutivos.

Sazonalidade s_t (painel verde). Ciclo anual bem definido com amplitude entre $-0,20$ e $+0,28$, correspondente aos picos de início de ano e vales de verão observados na série original. A amplitude cresce ligeiramente após 2015, evidenciando que os coeficientes de Fourier do modelo são variáveis no tempo e conseguem capturar

essa mudança gradual — algo que um modelo com sazonalidade fixa não seria capaz de fazer.

Componente de regressão r_t (painel laranja). Valores de pequena magnitude ($\pm 0,10$), com uma **quebra estrutural nítida em torno de 2015**: o componente passa de valores ligeiramente negativos para positivos e estáveis. Esse comportamento reflete diretamente a descontinuidade observada em `trend.unemploy` (Figura 1), que o BTVC acomoda por meio do ajuste dinâmico de $\hat{\beta}_{t,p}$, sem comprometer os demais componentes do modelo.

4.5 Métricas de Desempenho

Para quantificar a capacidade preditiva do modelo, calculamos o SMAPE (*Symmetric Mean Absolute Percentage Error*) e o MAE (*Mean Absolute Error*) sobre as 52 semanas do conjunto de teste:

$$\text{SMAPE} = \frac{1}{h} \sum_{t=1}^h \frac{|\hat{Y}_t - Y_t|}{(|\hat{Y}_t| + |Y_t|)/2} \times 100, \quad \text{MAE} = \frac{1}{h} \sum_{t=1}^h |\hat{Y}_t - Y_t| \quad (19)$$

onde $h = 52$ é o horizonte de previsão e $\hat{Y}_t$ são as previsões pontuais do modelo. O código a seguir calcula essas métricas diretamente sobre o conjunto `iclaims`:

```
import numpy as np
from orbit.models import KTR
from orbit.utils.dataset import load_iclaims

df      = load_iclaims()
n_test  = 52
df_train = df.iloc[:-n_test].copy()
df_test  = df.iloc[-n_test:].copy()

ktr = KTR(
    response_col      = "claims",
    date_col          = "week",
    regressor_col      = ["trend.unemploy", "trend.filling", "trend.job"],
    regressor_sign     = ["=", "=", "="],
    seasonality        = [52],
    estimator          = "pyro-svi",
    n_bootstrap_draws  = 500,
    num_steps          = 500,
```

```

        seed                = 2024,
    )
    ktr.fit(df=df_train)
    pred_df = ktr.predict(df=df_test)

    y_real = df_test["claims"].values
    y_pred = pred_df["prediction"].values

    smape = lambda r,p: np.mean(2*np.abs(r-p)/(np.abs(r)+np.abs(p)))*100
    mae    = lambda r,p: np.mean(np.abs(r-p))

    print(f"SMAPE : {smape(y_real, y_pred):.3f} %")
    print(f"MAE    : {mae(y_real, y_pred):.4f}")

```

Os resultados obtidos no conjunto `iclaims` com a configuração acima são da ordem de SMAPE $\approx 0,779\%$ e MAE $\approx 0,0963$, valores consistentes com o ajuste visual observado na Figura 4.

Para fins de referência comparativa, Ng, Wang e Dai (2021) reportam que, em um estudo de previsão com dados de demanda do Uber Eats em 10 países (horizonte de 28 dias, 6 cortes de backtesting), o BTVC alcança SMAPE médio de 0,174, superando o SARIMA(1, 1, 1)(1, 0, 0)₇ (0,191) e o Prophet (0,218). Os contextos são distintos, mas o resultado reforça a capacidade do modelo em séries com dinâmicas que variam ao longo do tempo, exatamente o que a análise exploratória das Seções 4.2 e 4.3 identificou no `iclaims`.

5 Discussão Crítica

Vantagens

1. **Coefficientes interpretativos e dinâmicos.** O analista obtém curvas $\hat{\beta}_{t,p}$ que mostram *quando* e *como* cada regressor afeta a resposta, impossível com ARIMA ou ARMAX de coeficientes fixos.
2. **Incorporação de experimentos (*lift tests*).** O framework Bayesiano permite usar resultados de experimentos controlados como prioris para μ_{reg} , calibrando os coeficientes. Isso é exclusivo do BTVC entre os modelos aqui comparados.
3. **Sazonalidade adaptativa.** A combinação de Fourier com kernel weighting gera sazonalidade que muda suavemente ao longo dos anos, superior ao SARIMA (sazonalidade fixa) e ao Prophet (pontos de mudança discretos).

4. **Escalabilidade via SVI.** A SVI escala linearmente com T e P , permitindo modelos com até ~ 50 regressores, inviável com MCMC completo usado em BSTS.
5. **Shrinkage automático.** A hierarquia (Equações 15–16) evita estimativas espúrias em períodos com dados esparsos, problema recorrente em dados de marketing com gastos intermitentes.

Limitações

1. **Sensibilidade a hiperparâmetros.** O número de knots J , a escala ρ do kernel Gaussiano e as prioris dos desvios σ_{lev} , σ_{reg} influenciam significativamente a suavidade dos coeficientes. Seleção inadequada pode levar a subajuste (J pequeno) ou coeficientes instáveis (J grande).
2. **Custo computacional relativo.** Embora mais eficiente que MCMC completo, a SVI ainda é mais custosa que estimação MLE (ARIMA).
3. **Identificabilidade.** Em séries curtas ou com alta multicolinearidade entre regressores, os $\beta_{t,p}$ individuais podem ser mal identificados.
4. **Ausência de testes de hipóteses frequentistas.** O paradigma Bayesiano fornece intervalos de credibilidade, mas não p -valores tradicionais, o que pode ser limitante em contextos que exigem inferência frequentista.
5. **Necessidade de regressores futuros.** Para previsão fora da amostra, os valores futuros de $x_{t,p}$ precisam ser conhecidos ou previstos separadamente.

6 Conclusão

O Modelo Bayesiano de Coeficientes Variáveis no Tempo (BTVC), implementado como KTR no pacote Orbit, representa uma contribuição metodológica relevante para a análise de séries temporais com regressores exógenos cujos efeitos evoluem ao longo do tempo. Ao combinar suavização por kernel, estrutura hierárquica Bayesiana e inferência variacional eficiente, o BTVC endereça a principal limitação dos modelos clássicos: a hipótese de parâmetros constantes.

A ilustração com o *dataset iclaims* demonstra a aplicabilidade do modelo a séries econômicas semanais com sazonalidade e regressores exógenos (Google Trends), confirmando que a decomposição adaptativa em tendência, sazonalidade e regressão fornece insights interpretáveis sobre a dinâmica da série.

Referências Bibliográficas

FARRIS, Paul W. *et al.* Marketing Return on Investment: Seeking Clarity for Concept and Measurement. **Applied Marketing Analytics**, v. 1, n. 3, p. 267–282, 2015. ISSN 2055-5881.

GELMAN, Andrew *et al.* **Bayesian Data Analysis**. 3. ed. [*S. l.*]: CRC Press, 2013. ISBN 978-1439840955.

HOFFMAN, Matthew D. *et al.* Stochastic Variational Inference. **Journal of Machine Learning Research**, v. 14, n. 5, 2013. ISSN 1532-4435.

NG, Edwin; WANG, Zhishi; CHEN, Huigang *et al.* Orbit: Probabilistic Forecast with Exponential Smoothing. **arXiv preprint**, arXiv:2004.08492, 2021. [stat.CO]. ISSN 2331-8422.

NG, Edwin; WANG, Zhishi; DAI, Athena. Bayesian Time Varying Coefficient Model with Applications to Marketing Mix Modeling. **arXiv preprint**, arXiv:2106.03322v4, 2021. [stat.AP]. ISSN 2331-8422.